



Universidad Tecnológica de Panamá

Centro Regional de Panamá Oeste

Facultad de Ingeniería en Sistemas Computacionales

Licenciatura en Ciberseguridad

Asignatura:

Inteligencia Artificial aplicada a la Ciberseguridad

Anteproyecto

Estudiantes:

Aracellys Camarena, 8-1025-956

Vivianne García, 20-14-8145

Giancarlos Ortiz, 8-1021-1540

Profesor:

Eric Solís

Título del Proyecto

Ataque Automatizado de Prompt Injection y Defensa mediante Clasificador de Machine Learning en Sistemas de Procesamiento de Lenguaje Natural

Introducción

En los últimos años, los modelos de inteligencia artificial basados en procesamiento de lenguaje natural (NLP) se han vuelto herramientas fundamentales en distintos sectores. Sin embargo, su popularidad también ha expuesto vulnerabilidades críticas que pueden ser explotadas por actores maliciosos.

Uno de los ataques más relevantes en este contexto es el **Prompt Injection**, una técnica en la que un atacante manipula el texto de entrada (prompt) de un modelo de lenguaje para lograr que este ignore sus instrucciones originales y ejecute acciones no autorizadas. Este tipo de ataque ha sido catalogado por OWASP como uno de los principales riesgos en aplicaciones que utilizan modelos de lenguaje de gran escala (LLM Top 10).

Este proyecto busca abordar esta problemática desde dos frentes: el ofensivo, construyendo un script automatizado que ejecute ataques de Prompt Injection, y el defensivo, desarrollando un clasificador de Machine Learning capaz de detectar y bloquear dichos ataques antes de que lleguen al modelo.

1. Planteamiento del Problema

Los sistemas de IA que utilizan NLP no cuentan, en la mayoría de los casos, con una capa de seguridad que filtre el contenido antes de que el input llegue al modelo. Esto significa que cualquier usuario puede enviar texto diseñado para manipular el comportamiento del sistema, evadir restricciones y obtener respuestas no permitidas.

Este vacío de seguridad representa un riesgo crítico en entornos de producción, donde los modelos de lenguaje están expuestos al público general. Actualmente no existe un estándar establecido para interceptar y bloquear estos ataques de forma previa, lo que hace urgente el desarrollo de soluciones defensivas basadas en machine learning.

2. Objetivos

Objetivo General

Demostrar que es posible ejecutar un ataque automatizado de Prompt Injection contra un modelo de lenguaje, y al mismo tiempo desarrollar un clasificador de Machine Learning que sea capaz de detectar y bloquear estos ataques antes de que lleguen al modelo.

Objetivos Específicos

1. **Construir un script ofensivo** que envíe de forma automatizada prompts maliciosos contra la API de Groq, y que registre cuántos de esos ataques lograron evadir las restricciones del modelo.
2. **Crear un dataset etiquetado** con los resultados obtenidos durante el ataque, compuesto por prompts maliciosos y prompts normales (benignos), para usarlo como base de entrenamiento del clasificador.
3. **Entrenar un clasificador de Machine Learning** usando algoritmos accesibles como Naive Bayes o Regresión Logística, capaz de identificar si un prompt es malicioso o no con una precisión superior al 85%.
4. **Integrar el clasificador como capa defensiva**, de manera que actúe antes de que el input llegue al modelo, bloqueando automáticamente los intentos de ataque en tiempo real.
5. **Evaluar el rendimiento del sistema completo** utilizando métricas estándar como precisión, recall y F1-score, para verificar que la defensa funciona correctamente.

3. Alcance del Proyecto

- El ataque se realiza exclusivamente contra la **API de Groq**, utilizando el modelo **LLaMA 3.3 70B**, en un entorno controlado propio. No se ataca ningún sistema externo ni de terceros.
- El clasificador se desarrolla en **Python**, utilizando la librería **scikit-learn**.
- El dataset mínimo a construir es de **200 prompts**: 100 clasificados como maliciosos y 100 como benignos.
- El entorno de trabajo es completamente local y controlado, garantizando que el proyecto no cause daño a sistemas reales.

4. Justificación

Este proyecto es relevante porque combina tres áreas fundamentales del perfil de un profesional en ciberseguridad moderno: el procesamiento de lenguaje natural (NLP), el machine learning y la ciberseguridad tanto ofensiva como defensiva.

Además, responde directamente a uno de los vectores de ataque más críticos identificados actualmente por **OWASP en su lista LLM Top 10**, que cataloga el Prompt Injection como la amenaza número uno en aplicaciones de inteligencia artificial generativa.

Al ejecutar el proyecto en un entorno controlado y reproducible, el equipo podrá vivenciar de primera mano tanto el proceso de ataque como el de defensa, adquiriendo competencias prácticas que son altamente valoradas en la industria de la seguridad informática.

5. Metodología

El proyecto se divide en cinco fases claramente definidas:

Fase 1: Reconocimiento

Se investigan las técnicas de Prompt Injection más documentadas, utilizando como fuentes principales la literatura académica disponible y las guías publicadas por **OWASP**. El objetivo es entender qué tipos de prompts maliciosos existen, cómo funcionan y cuáles son los más efectivos.

Fase 2 : Ataque

Se desarrolla un **script en Python** que envía de forma automatizada una serie de prompts maliciosos a la API de Groq. Este proceso se conoce como *fuzzing de prompts*. El script registra las respuestas del modelo y determina en cuáles casos el ataque fue exitoso, es decir, en cuáles el modelo ignoró sus restricciones.

Fase 3 : Recolección de Datos

Con los resultados del ataque se construye un **dataset etiquetado en formato CSV**. Cada fila del dataset contiene un prompt y una etiqueta que indica si es malicioso (1) o benigno (0). Este dataset es la materia prima para entrenar el clasificador.

Fase 4 : Defensa

Se entrena el **clasificador de Machine Learning** usando scikit-learn. Se prueban algoritmos como Naive Bayes y Regresión Logística por su facilidad de implementación y buenos resultados en clasificación de texto. Una vez entrenado, el clasificador se integra como una capa previa al modelo: si detecta un prompt malicioso, lo bloquea antes de que llegue a la API.

Fase 5 : Evaluación

Se realizan pruebas completas del sistema usando métricas estándar: **precisión** (qué tan exacto es el clasificador), **recall** (qué tan bien detecta los ataques) y **F1-score** (balance entre ambas métricas). Los resultados se visualizan con gráficos generados en **matplotlib**.

6. Resultados Esperados

Al finalizar el proyecto, se espera obtener los siguientes entregables:

- Un **script ofensivo funcional** que incluya un reporte con la tasa de evasión por categoría de ataque, mostrando cuántos y qué tipo de prompts lograron engañar al modelo.
- Un **clasificador de Machine Learning** entrenado con una precisión superior al 85%, capaz de distinguir prompts maliciosos de prompts normales.
- Un **pipeline completo y funcional** que siga el flujo: input del usuario → clasificador → bloqueo (si es malicioso) o paso al modelo (si es benigno).
- Un **informe con análisis comparativo** que muestre el comportamiento del sistema antes y después de implementar la defensa, evidenciando la efectividad del clasificador.

7. Herramientas y Tecnologías a Utilizar

Herramienta	Uso en el proyecto
Python	Lenguaje principal para el script ofensivo, el clasificador y las pruebas
API de Groq (LLaMA 3.3 70B)	Objetivo del ataque de Prompt Injection
scikit-learn	Entrenamiento del clasificador de Machine Learning
CSV / pandas	Almacenamiento y manejo del dataset etiquetado
matplotlib	Visualización de métricas y resultados
OWASP LLM Top 10	Referencia técnica para las técnicas de ataque

Conclusión

Este proyecto representa una oportunidad práctica y directamente aplicable para entender los riesgos reales que enfrentan los sistemas de IA modernos. Al combinar el desarrollo de un ataque real con la construcción de una defensa automatizada, el equipo podrá demostrar de manera concreta cómo los principios de machine learning pueden aplicarse para proteger sistemas de inteligencia artificial contra amenazas emergentes. El resultado final no solo tiene valor académico, sino que refleja habilidades técnicas muy demandadas en el campo de la ciberseguridad aplicada a la inteligencia artificial.